

### מבוא

BCIs מאפשרים תקשורת בין מוח האדם למכשיר טכנולוגי. על מנת להעביר מסרים, נשלחים אותות חשמליים בין נוירונים. תבנית זו מוקלטת, לרוב בעזרת EEG, והמידע מומר לפקודה הניתנת למכשיר- תהליך המתבצע תוך למידה. Gao, Xiaorong, et al (2003). הקלטות EEG מייצגת את הפעילות המסונכרנת של אוכלוסיית נוירונים פרמידלים בקורטקס שכיוונם מאונך לקרקפת, ומוזדזת את עוצמת השוק החשמלי על אלקטרודה בכל נק' זמן. Smith, S. J. (2005). הפקודה הניתנת למכשיר נעשית בעזרת Motor Imagery- מצב בו קיים ייצוג של פעולה מוטורית בזיכרון העובד, אך לא מופקת מכך תנועה. Decety, J. (1996)

המרת MI לפעילות מתבצעת באופן הבא:


עבור כל חזרה מופקים מאפיינים המשמשים בביצוע קלסיפיקציות על הנתונים (Höller, Y., Bergmann, J et al (2013- מאפיינים אלו מכילים ניתוחי מידע והם בעלי רמת יעילות שונה בסיווג הנתונים (Vega-Escobar, L. et al (2015). תהליך זה נקרא Feature extraction.

בהמשך, המאפיינים נקלטים במסווג שמטרתו- לתרגם את הקלט לפקודות. המסווג יוצר סף, באופן סטטיסטי, בהתאם לערך הפיצ'רים ולכוונת הסיווג הנתונה, והוא מהווה את מודל החיזוי. זהו שלב האימון: Offline training.

(Aggarwal, S., & Chugh, N. (2019).

כדי לבדוק את טיב המודל, מחולקים הנתונים לקבוצות "אימון" ו"מבחן" (Cross-validation). המצבים האפשריים: overfitting- המודל מייצג גם רעש ותכונות ייחודיות של נתוני האימון (Overfit, תרשים 1). under-fitting- לא מייצג את השתנות הנתונים (Underfit, תרשים 1), ו-Good-fit- מייצג נאמנה את אופי הנתונים. (Good fit, תרשים 1).

Jabbar, H., & Khan, R. Z. (2015)



שימוש ביותר נתונים כסט האימון יכול לייצר מודל עם טיב התאמה גבוה יותר, שכן יהיה מדגם רב יותר לבסס עליו את הסף שנוצר על ידי המסווג, אך מנגד, יהיה קשה לבחון את טיב ההתאמה וזאת מפני שיהיו מעט נתוני מבחן.

בדיקה שתתבצע על סט נתוני האימון- תפיק, לכאורה, טיב התאמה גבוה. אך טיב זה עלול להעיד על overfitting, ולא באמת ניתן לדעת מהו טיב ההתאמה.

על מנת להימנע מ-overfitting, ניתן לבצע בחירה של רק חלק מהמאפיינים- אלו המכילים את המידע הרב ביותר אשר ישמשו לבניית המודל הרצוי. תהליך זה נעשה באמצעות אלגוריתם neighborhood component analysis.

### שיטה:

חלק 1- הנתונים שניתחנו: - עד 2 משפטים

סטראקט נתונים: בשדה "data"- ערכי הפלט של 4 אלקטרודות EEG. שתיים בצד השמאלי ושתיים בימני.  
 הנתונים נאספו במשך 6 שניות בקצב של 128Hz. בשדה "attribute", עבור כל נסיון מצויין הכיוון אותו דמיין הנבדק (כמו גם ערך "הזזה" ו"ארטיקפט").

חלק 2- טעינת החלק הרלוונטי בנתונים:

מהנתונים הוצאנו את החלק הרלוונטי אודות אלקטרודות C3 וC4 בצד ימין ושמאל. נתונים אלו הוכנסו לסטראקט Data תחת כל side מתאים. משתנה sideName מקבל את שם הצד ומכניסו לסטראקט.

```
%creat a struct for all relevant data and arrange it
Data.all = P_C_S.data;
Data.CaseName = cell(1,nchannels*numberSides); %naming the different combinations of electrode and attribute
Data.labels = strings(technicalPar.nTrials,1); %lable trails as the suitable attribute
```

```

countCol = 1;
for i = 1:numberSides %loop over left and right
    side_attribute = sides(i);
    Data.indexes.(sides{i}) = find(P_C_S.attribute(technicalPar.clasRow(i),:)==1); %Find the places of the
corresponding attribute
    Data.labels(Data.indexes.(sides{i})) = side_attribute; %Name as the corresponding
attribute
    for j = 1:nchannels %loop over C3 and C4
        sideName = char(side_attribute + name_of_chan(j)); %Combine attribute and electrode
into one name
        Data.(sideName) = Data.all(Data.indexes.(sides{i}),:,channels(j)); %arrange data by name
        Data.CaseName{1,countCol} = sideName;
        countCol = countCol+1;
    end
end

```

### חלק 3 א' - Pwelch הגדרת נתונים:

טכניקת Welch מעריכה את צפיפות הסיגנל בעזרת מציאת תבניות חוזרות.

```

%perform PWelch
%loop over all sides and electrodes:
for i = 1:numberSides
    for j = 1:length(technicalPar.Channels)
        side_attribute = technicalPar.classes(i);
        sideName = char(side_attribute + name_of_chan(j));
        Data.PWelch.(sideName) = pwelch(Data.(sideName)(:,(technicalPar.imagery_time*fs))',...
            technicalPar.windowLength,technicalPar.Noverlap,technicalPar.frequency,technicalPar.fs);
    end
end

```

בוצעה עבור התנאים השונים תוך שימוש בוקטור הזמן שבו התרחש דמיון הצדדים (imagery\_time), וזאת על מנת להפיק את המידע בזמן הרלוונטי לאלגוריתם הניבוי.

```
plots('Pwelch',Data,technicalPar)
```

### פונקציית *plots*:

פונקציה המציגה באופן ויזואלי נתונים, בהתאם לסוג ההצגה הנדרש.

מקבלת סטרינג סוג וסטאקרטי דאטא ופרטים טכניים ומציגה את סוג הדאטא המבוקש באופן ויזואלי.

```
case 'Pwelch'
%in that case: compute Pwelch over all condition
figure('Units','normalized','Position',technicalPar.Vis.PositionOffFig);
for i = 1:length(Data.CaseName) %loop over all cases:
    subplot(technicalPar.nchans,technicalPar.nClassification,i)
    plot(technicalPar.frequency,mean(Data.PWelch.(Data.CaseName{i}),2))
    title(Data.CaseName{i},'FontSize',15);hold on
    if(mod(i-1,technicalPar.nchans)==0)
        ylabel('power spectral density','FontSize',15)
    end
    if(i>=3) %label only some subplots
        xlabel('Frequency[Hz]','FontSize',15)
    end
end
end
hold off

%visualize the difference of average intensity of frequencies between
%classes within each electrode as a function of frequency.
figure('Units','normalized','Position',technicalPar.Vis.PositionOffFig);
for i = 1:length(technicalPar.chansName) %loop over C3 and C4
    subplot(technicalPar.nchans,1,i)
    plot(technicalPar.frequency,mean(Data.PWelch.(Data.CaseName{i}),2),'r') %left
    imagination
    hold on
    plot(technicalPar.frequency,mean(Data.PWelch.(Data.CaseName{i+2}),2),'b')
    %right imagination
```

```

title(strcat('Power Spectrom diff',{' '}, (technicalPar.chansName{i})), 'FontSize',15)
ylabel('power spectral density','FontSize',15)
if(i>1) %label only some subplots
    xlabel('Frequency[Hz]','FontSize',15)
end
legend(technicalPar.classes{1},technicalPar.classes{2})
end

```

#### חלק 4 - הצגת הדאטא:

קריאה לפונקציית פלוטס לסוג הצגת הדאטא

```
plots('dataviz',Data,technicalPar)
```

הצגת כל הדאטא של ימין ושמאל מ30 מתוך 64 מדידות באופן אקראי

```

case 'dataviz'
%in that case: visualize the EEG signal of 20 random trails For each class,
%each subplot plots the data from both channels(C3 and C4).
for clss =1: size(struct2table(Data.indexes),2) % runs over classes
    timeVec = [0:length(technicalPar.time_vector)-1]/technicalPar.fs;
    fig=figure('Units','normalized','Position',technicalPar.Vis.PositionOfFig);
    set(gca,'YDir','normal','FontSize',15)
    randIndex_trails = Data.indexes.(technicalPar.classes{clss})...
        (randperm(length(Data.indexes.(technicalPar.classes{clss}))),...
        (technicalPar.Vis.plotPerRow*technicalPar.Vis.plotPerCol)); %choose rand
trails
    sgtitle(technicalPar.classes{clss} + " " + "Imagery Amplitude as a function of
time",'FontSize',15)
    for i = 1:length(randIndex_trails) %loop over all selected trails
        subplot(technicalPar.Vis.plotPerCol,technicalPar.Vis.plotPerRow,i)
        C3 = plot(timeVec,Data.all(randIndex_trails(i),:,1),'b'); %signal from c3
        hold on
        C4 = plot(timeVec,Data.all(randIndex_trails(i),:,2),'r','LineStyle','-'); %signal
from c4

```

```

ylim([-15,15])

end

%legend:
Legendpos = legend('C3','C4');
set(Legendpos,'Position',[0.848091556210113 0.925793650793651
0.113690476190476 0.071031746031746],'Units','normalized');

%labels for the whole graph
han=axes(fig,'visible','off');
han.XLabel.Visible='on';
han.YLabel.Visible='on';
han.Title.Visible='on';
xlabel(han,'time [sec]','FontSize',15);
ylabel(han,'Amplitude[\mu V]','FontSize',15);

end

```

#### חלק 5- פיצ'רים והצגתם:

את הפיצ'רים אנחנו מייצרים בתוך פונקציית featureCreate המקבלת את סטאקרטי הדאטא, הפרמטרים הטכניים ופרטי הפיצ'רים ומחזירה את סטראקט הפיצ'רים מחושב.

```
feat = featureCreate(Data.all,technicalPar,feat); %calc and extract all features
```

1. חילקנו את העוצמה על פי טווחי תדרים. ניתן לראות מהצגת הדאטא כי ישנם הבדלים גדולים בטווח תדרי Beta ולכן התמקדנו בחלק זה. לכל תדירות חישבנו גם את עוצמת הבנד היחסית.

```

%creat struct which contains features
%band power:
feat.bandPower{1} = {[8,12],[5.5,6]}; %Alpha
feat.bandPowerName{1} = "Alpha";
feat.bandPower{2} = {[12,15],[3.5,6]}; %Low Beta
feat.bandPowerName{2} = "Low Beta 1";
feat.bandPower{3} = {[15,19],[3.5,6]}; %Low Beta

```

```

feat.bandPowerName{3} = "Low Beta 2";
feat.bandPower{4} = {[19,23],[1.2,2.7]}; %High Beta
feat.bandPowerName{4} = "High Beta 1";
feat.bandPower{5} = {[23,30],[1.2,2.7]}; %High Beta
feat.bandPowerName{5} = "High Beta 2";
feat.bandPower{6} = {[30,34],[4,6]}; %Gamma
feat.bandPowerName{6} = "Gamma";

```

העצמה הגולמית לטווח תדרים- בעזרת פונ' bandpower המקבלת קצב דגימה, טווח הזמן וטווח התדרים שהגדרנו בfeat.bandPower. הפונ' מחזירה כפלט את העצמה הממוצעת בטווח התדרים. העצמה היחסית לטווח תדרים - באופן דומה חישבנו את העצמה הממוצעת ולאחר מכן חילקנו בעצמה הכוללת בטווח התדרים.

```

%% raw bandpower
feat.matrix(:,featindex) = ...
    (bandpower(Data(:,tRange,i)',technicalPar.fs,feat.bandPower{j}{1}));
feat.featLables{featindex} =char("Bandpower -
"+technicalPar.chansName(i)+newline+...
    " "+ feat.bandPowerName{j} +": " + feat.bandPower{j}{1}(1)+"Hz - "...
    +feat.bandPower{j}{1}(2)+"Hz");
featindex = featindex + 1;
%% relative bandpower
totalBP = bandpower(Data(:,tRange,i)');
feat.matrix(:,featindex) = feat.matrix(:,featindex-1)./totalBP;
feat.featLables{featindex} =char("Relative Bandpower -
"+technicalPar.chansName(i)+newline+...
    " "+ feat.bandPowerName{j} +" frequency: " + feat.bandPower{j}{1}(1)+"Hz - "...
    +feat.bandPower{j}{1}(2)+"Hz");
featindex = featindex + 1;

```

2. כלל העצמה - מחושבת ע"י סכימת עצמת התדרים בעזרת פונ' sum.

```

%% total power
feat.matrix(:,featindex) = sum(PW);

```

```

feat.featLables{featindex} = char("Total Power - " + technicalPar.chansName{i});
%name features accordingly
featindex = featindex + 1;

```

3. שורש כלל העצמה - חושב ע"י סכימת כל הזמנים בחלון ומציאת שורש ריבועי של הסכום בעזרת פונ'  $\text{sqrt}$ . ע"פ הנוסחה הבאה:

$$\text{root total power} = \sqrt{\sum p(f)}$$

```

%% root total power
feat.matrix(:,featindex) = sqrt(power);
feat.featLables{featindex} = char("Root Total Power - " + technicalPar.chansName{i});
%name features accordingly
featindex = featindex + 1;

```

4. ממוצע אורכי השיפועים - סכימת השיפועים הנקודתיים ל  $Y$  ומיצועם ע"י חילוק באורך מטריצת  $P_{\text{Welch}}$ .

```

%% root total power
feat.matrix(:,featindex) = sqrt(power);
feat.featLables{featindex} = char("Root Total Power - " + technicalPar.chansName{i});
%name features accordingly
featindex = featindex + 1;

```

5. ממוצע כללי - חושב בעזרת פונקציית mean המוצאת את הערך הממוצע.

```

%% ArithmeticMean
feat.matrix(:,featindex) = mean(PW);
feat.featLables{featindex} = char("Arithmetic Mean - " + technicalPar.chansName{i});
%name features accordingly featindex = featindex + 1;

```

6. אנטרופיית רני - חישוב פונ' ההסתברות של  $P_{\text{Welch}}$ , מציאת הלוג2 של סכומה והכפלה ב-(1-) למנוע ערכים שליליים.

```

%% Renyi Entropy

```



```

% Parameter
alpha = 2; % alpha
% Entropy
En = prob.^ alpha;
feat.(type)(:,featindex) = (1 / (1 - alpha)) * log2(sum(En));
feat.featLables{featindex} = char("Renyi Entropy - " + technicalPar.chansName{i});
%name features accordingly
featindex = featindex + 1;

```

7. ספקטרל רגעי: הפיכת הסיגנל לפונ' הסתברות וחישוב התדר הממוצע

$$spectral\ moment = \sum pnorm(f)f$$

```

%% spectral Moment
prob = PW./sum(PW); %creat a probability function by normalizing the power by
the total power
feat.(type)(:,featindex) = (technicalPar.frequency*prob)';
feat.featLables{featindex} = char("Spectral Moment - "+ technicalPar.chansName{i});
%name features accordingly
featindex = featindex + 1;

```

8. אנטרופיה ספקטרלית - הכפלו את פונ' ההסתברות בלוג2 שלה והכפלה ב-(1-) למנוע ערכים שליליים.

$$spectral\ entropy = - \sum pnorm(f) \log_2(pnorm(f))$$

```

%% Spectral entropy
feat.(type)(:,featindex) = (-sum(prob .* log2(prob),1))';
feat.featLables{featindex} = char("Spectral Entropy - "+
technicalPar.chansName{i});%name features accordingly
featindex = featindex + 1;

```

9. גבנוניות - מדד למידת הריכוז של פונקציית צפיפות. חושב בעזרת פונ' kurtosis.

```

%% Kurtosis
feat.(type)(:,featindex) = kurtosis(PW);
feat.featLables{featindex} = char("Kurtosis - " + technicalPar.chansName{i}); %name

```

```
features accordingly
featindex = featindex + 1;
```

10. צידוד - מדד לחוסר הסימטריה של פונקציית צפיפות. חושב בעזרת פונ' skewness.

```
%% skewness
feat.(type)(:,featindex) = skewness(PW);
feat.featLables{featindex} = char("Skewness - " + technicalPar.chansName{i}); %name
features accordingly
featindex = featindex + 1;
```

11. סטיית תקן - חושב בעזרת פונקציית std המוצאת את סטיית התקן.

```
%% Standard Deviation
feat.(type)(:,featindex) = std(PW);
feat.featLables{featindex} = char("Standard Deviation - " +
technicalPar.chansName{i}); %name features accordingly
featindex = featindex + 1;
```

12. שונות - חושב בעזרת פונקציית var המוצאת את השונות.

```
%% Variance
feat.(type)(:,featindex) = var(PW);
feat.featLables{featindex} = char("Variance - " + technicalPar.chansName{i}); %name
features accordingly
featindex = featindex + 1;
```

חלק 5 - Z-Score:

ביצוע Z-Score על מטריצת הפיצ'רים על מנת לנרמל את הערכים.

```
[feat.matrix,trainavg,trainstd] = zscore(feat.matrix); %perform zscore on all features so
that columns have mean 0 and sd 1
```

$$Z_x = \frac{x - \mu}{\sigma}$$

$x$  - ערך התצפית  $\mu$  - תוחלת האוכלוסייה  $\sigma$  - סטיית התקן של האוכלוסייה  $Z_x$  - ציון התקן של התצפית

חלק 6 - בחירת הפיצ'רים:

בעזרת פונ' fsenca הבוחרת פיצ'רים בעזרת השוואת רכיבים שכנים ביצענו אופטימיזציה של הפיצ'רים והמשקולות ובחרנו את הפיצ'רים הסיגניפיקנטיים ביותר להדבל בין הצדדים.

```

Selection = fscnca(feats.matrix,Data.labels); %Feature selection using neighborhood
% component analysis for classification
weights = Selection.FeatureWeights;
[~, featOrder] = sort(weights, 'descend'); %Sort in descending order
featindex = featOrder(1:feats.selectedFeat-featDeduct+1); %Choose most important features
%featindex is the index of the selected best features.
matrixFeatSelected = feats.matrix(:,(featindex));
%matrixFeatSelected is the selected matrix of weight

```

### חלק 7 - אימון מודל cross validation :

בדיקת מספר הפיצ'רים שיביאו לנו את התוצאות האופטימליות בבדיקתם על בסיס נתוני הלמידה. המשתנה bestFeatDeduct מכיל את מספר הפיצ'רים האופטימלי להחסרה, accuracy מכיל את אחוז דיוק הוואלידציה, trainError את סטיית התקן, confusionMatrixSum את נתוני מטריצת הקונפיוז'ן, matrixFeatSelected את מטריצת הפיצ'רים האופטימלית וfeatindex את איזה פיצ'רים נבחרו.

```

%% feature selection
[accuracySave,bestFeatDeduct]=deal(0);
for featDeduct=1: feats.selectedFeat %loop over selected features
    accuracy = trainingfeat(feats,Data,technicalPar.nTrials,featDeduct);
    if mean(accuracy)>accuracySave % if this compilation of features is better than
previous
        accuracySave = mean(accuracy);
        bestFeatDeduct = featDeduct;
    end
end
[accuracy,trainError,confusionMatrixSum,matrixFeatSelected,featindex] ...
= trainingfeat(feats,Data,technicalPar.nTrials,bestFeatDeduct);

```

**פונקציית trainingfeat:** מקבלת סטראקטי פיצ'רים ודאטא, מספר וחזרות ומונה את מספר הפיצ'רים להחסיר. לוקחים באופן אקראי חלק מהנתונים ומשתמשים בהם כמבחן ובאשר משתמשים ללמידה. בעזרת פונ' classify המבצעת אנליזה דיסקרימיננטית, אנחנו בונים cell המכיל את כלל התוצאות וסטיות התקן על מנת לאבחן את למידת המודל. מחזירה את אחוז הדיוק, סטיית התקן, מטריצת הקונפיוז'ן, מטריצת הפיצ'רים ואיזה פיצ'רים נבחרו.

```

%this section recives features matrix and a lable and chooses the

```

```

%best features
Selection = fscnca(feats.matrix,Data.labels); %Feature selection using neighborhood
% component analysis for classification
weights = Selection.FeatureWeights;
[~, featOrder] = sort(weights, 'descend'); %Sort in descending order
featindex = featOrder(1:feat.selectedFeat-featDeduct+1); %Choose most important features
%featindex is the index of the selected best features.
matrixFeatSelected = feat.matrix(:,(featindex));
%matrixFeatSelected is the selected matrix of weight

%% Train model with cross-validation

idxSegments = mod(randperm(trialNumber),feat.selectedFeat)+1; ...
    %split trails randomly to n=trainingPar groups
confusionMatrixSum = zeros(size(struct2table(Data.indexes),2)...
    ,size(struct2table(Data.indexes),2)); %creat primary confusion matrix

%perform this process on choosen "train" group and test it on "test" group
for i = 1:feat.selectedFeat %loop over selected features
    validation = logical(idxSegments == i);
    trainingSegment = logical(idxSegments ~= i);
    [results{i},trainError{i}] = classify(matrixFeatSelected(validation,:)...
        ,matrixFeatSelected(trainingSegment,:),Data.labels(trainingSegment));
    accuracy(i) = sum(results{i} == Data.labels(validation)); %sum the number of correct
results
    accuracy(i) = accuracy(i)/length(results{i})*100;

    %put recived data in the confusion matrix
    confusionMatrix = confusionmat(Data.labels(validation),results{i});
    confusionMatrixSum = confusionMatrixSum + confusionMatrix;
end

```

### חלק 8 - PCA :

השתמשנו בפונקציה PCA של מטלב, המבצעת התמרה לינארית של נתונים למערכת קואורדינטות חדשה שבה המידע המופק הוא אורתוגונלי ובעל שונות הולכת וקטנה, שאוצר בתוכו את המידע הרב ביותר שניתן לשמר במימד הפלט הרצוי. EEG.L. et al (2017). בעזרת דחיסת הנתונים אנו יכולים להציג אותם בפונ' plots.

```
plots('pca',Data,technicalPar,null,feat.matrix)
```

```
comp = pca(featMatrix,'NumComponents',3); %compute pca and choose the 3 components
                                         %who holds the greatest variability
component = (featMatrix * comp);        %coded matrix
```

### חלק 9 - שימוש במנבא לנבא את צדדי נתוני המבחן

בחלק זה אנו טוענים את נתוני המבחן ובעזרת מטריצת הפיצ'רים שבנינו מסווגים את קלטי המבחן לצדדים המתאימים. התוצאה מתקבלת בדומה ללימוד הפיצ'רים בעזרת פונ' classify במערך predicted\_class בהתאם ללייבלים שסופקו. החישוב מתבצע על בסיס מטריצת הפיצ'רים שנלמדה בחלק 7.

```
%% Test
load(testDataName) %Load test set
test_data = data(:,1:length(technicalPar.Channels));

%Apply feature extraction procedure to the test set:
feat.TestFeatMat = zeros(size(test_data,1),feat.nFeat); %Create an initial matrix which
will contain the features
feat = featureCreate(test_data,technicalPar,feat,'Testing'); %extract features
%Test feature selection
feat.Testing = feat.Testing(:,featindex); %choose the corresponding features
feat.Testing = (feat.Testing - trainavg(:,featindex))./trainstd(:,featindex); %scale as train
data set

%Apply classifier to the features extracted from the test set to obtain a predicted
%classification:
```

```
predicted_class = classify(feat.Testing,matrixFeatSelected,Data.labels);
```

### תוצאות:

#### ביצועי המודל:

מוצגת דוגמת ביצועי המודל על הרצה בה התבצע שימוש ב-10 פיצ'רים:

Number of optimal features is: 10

The validation accuracy is: 86.8457% with standard deviation of: 9.40293%

The training accuracy is: 90.1522% with standard deviation of: 1.34984%

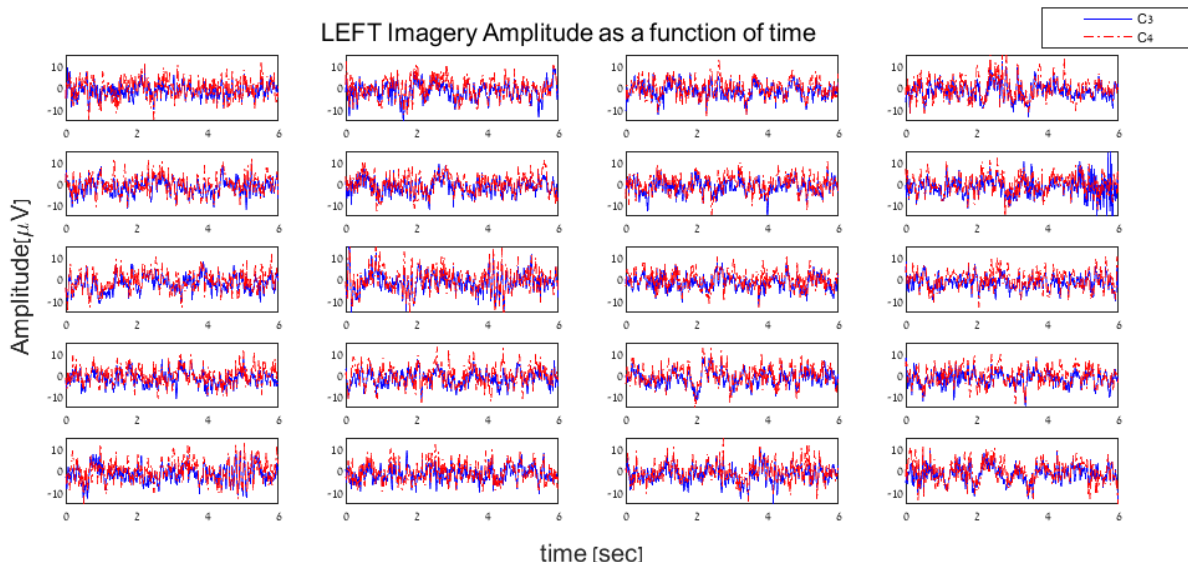
השורה הראשונה היא ביצועי סט האימון (128 הניסויים), והשנייה- סט המבחן (32 הניסויים).

#### ביצועי המודל מבדיקה ב-Moodle, על סט המבחן:

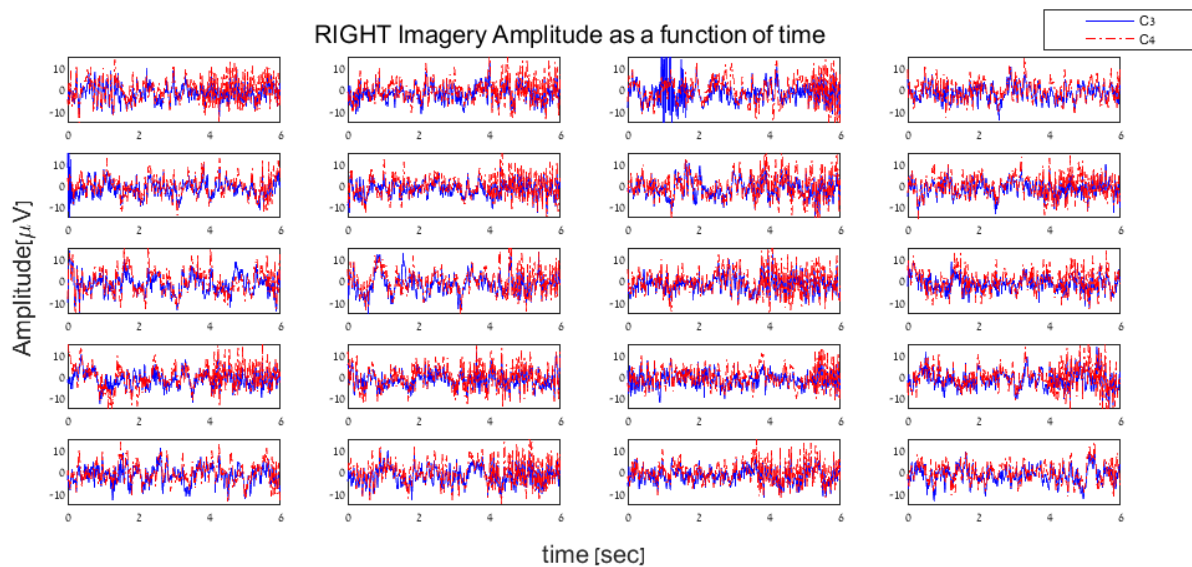
אחוזי דיוק של 87.50%.

### Visualization

אמפליטודת הקלטת ה-EEG מאלקטרודות C3 (כחול) ו-C4 (אדום) כפונקציה של זמן, עבור 20 ניסויים רנדומליים (מיוצגים כסאב-פלוטים), כשהנבדק חשב "שמאל":

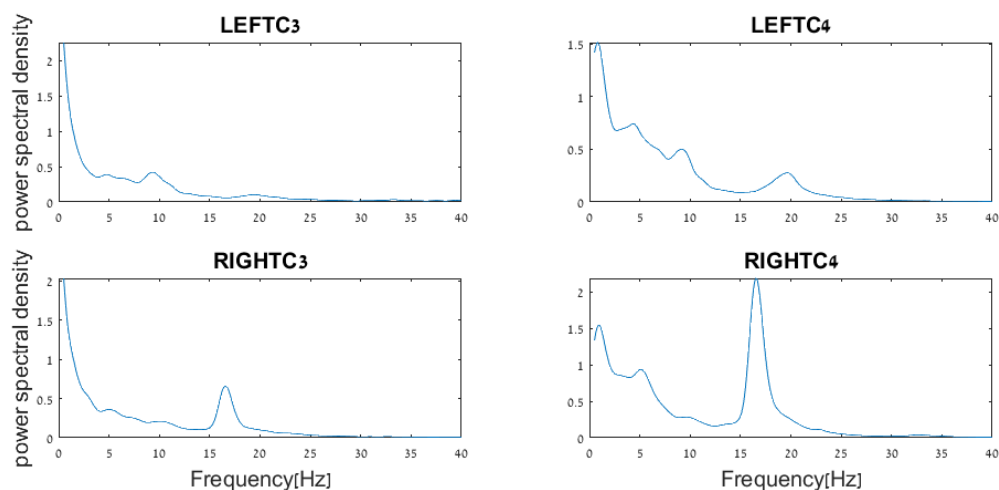


אמפליטודת הקלטת ה-EEG מאלקטרודות C3 (כחול) ו-C4 (אדום) כפונקציה של זמן, עבור 20 ניסויים רנדומליים (מיוצגים כסאב-פלוטים), כשהנבדק חשב "ימין":



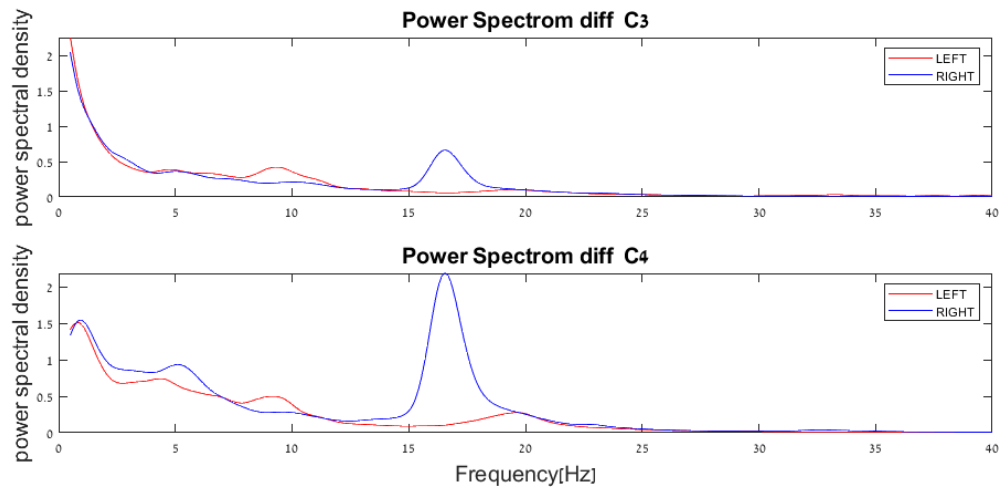
### power spectrum

צפיפות כוח ספקטרלית של סיגנל ה-EEG (בכחול) כתלות בתדר, מעבר לכל הניסויים, עבור שילובי- הערוץ ממנו הוקלט והצד שהנבדק דמיין (מיוצגים כסאב-פלוטים).



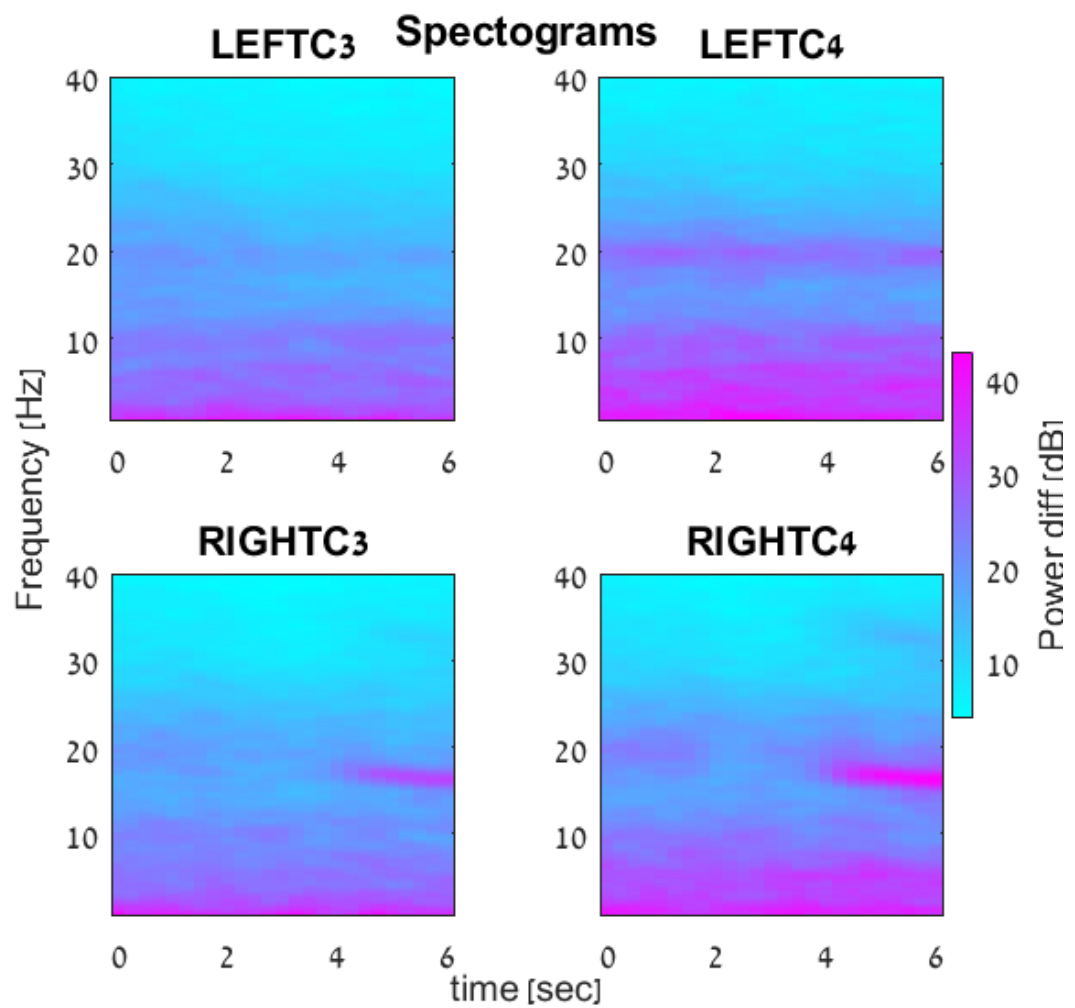
### power spectrum

צפיפות כוח ספקטרלית של סיגנל ה-EEG כתלות בתדר, מעבר לכל הניסויים, כשהנבדק דמיין ימין (אדום) או שמאל (כחול), עבור הערוץ ממנו הוקלט (מיוצג כסאב-פלוט).



### ספקטוגרמה

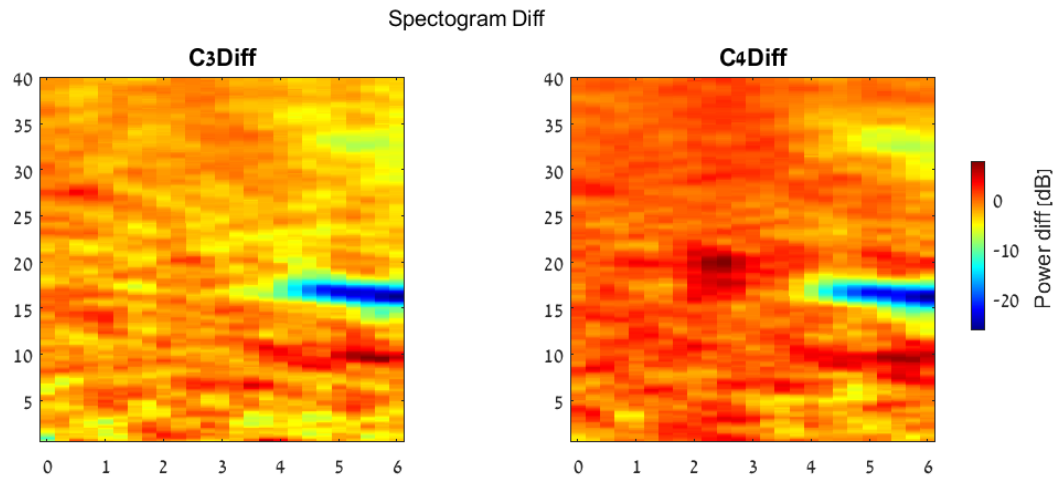
עוצמת הסיגנל כתלות בתדירות (ציר ה-Y) ובזמן (ציר ה-X) מעבר לכל הניסויים, עבור שילובי- הערוץ ממנו הוקלט והצד שהנבדק דמיין (מיוצגים כסאב-פלוטים).



### ספקטוגרמת הפרש התיוגים




עוצמת הפרש הסיגנל בעת דמיון "ימין" ל"שמאל", כתלות בתדירות (ציר ה-Y) ובזמן (ציר ה-X), עבור הערוץ ממנו הוקלט (מיוצג כסאב-פלוט).




#### התפלגות מאפייני ה-Bandpower ו-Relative Bandpower:

הסתברות הסיגנל כתלות בסטיית התקן, כשהנבדק דמיון "ימין" (כתום) ו"שמאל" (כחול), עבור תדר Alpha, עבור הקלטה מאלקטרודה C3 ו-C4:

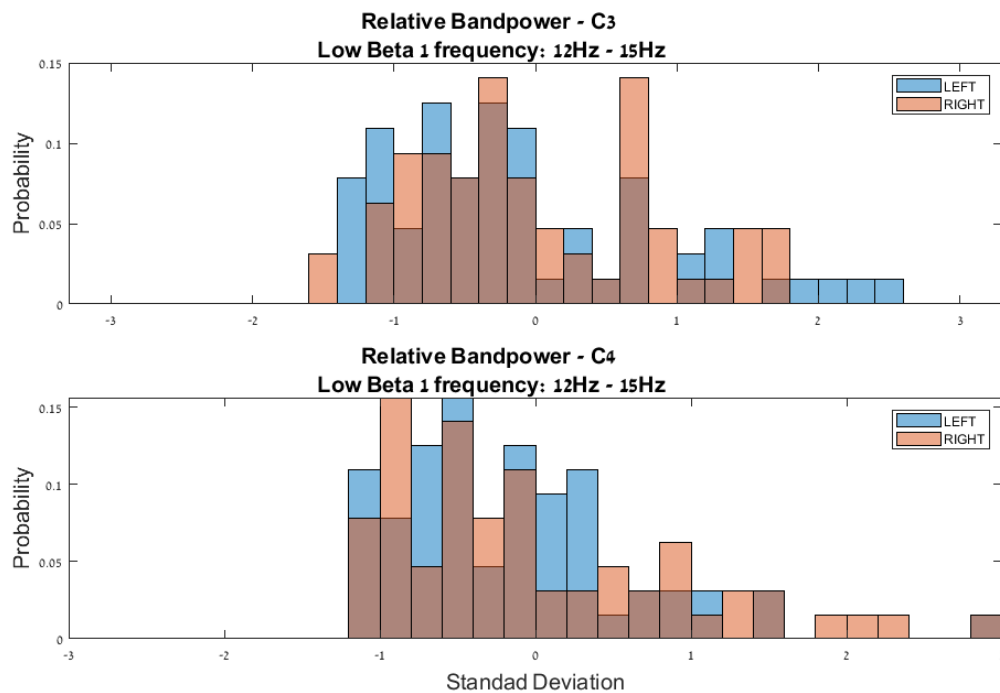
הסתברות הסיגנל כתלות בסטיית התקן, כשהנבדק דמיון "ימין" (כתום) ו"שמאל" (כחול), עבור תדר Alpha ביחס לתדרים הנוספים, עבור הקלטה מאלקטרודה C3 ו-C4:



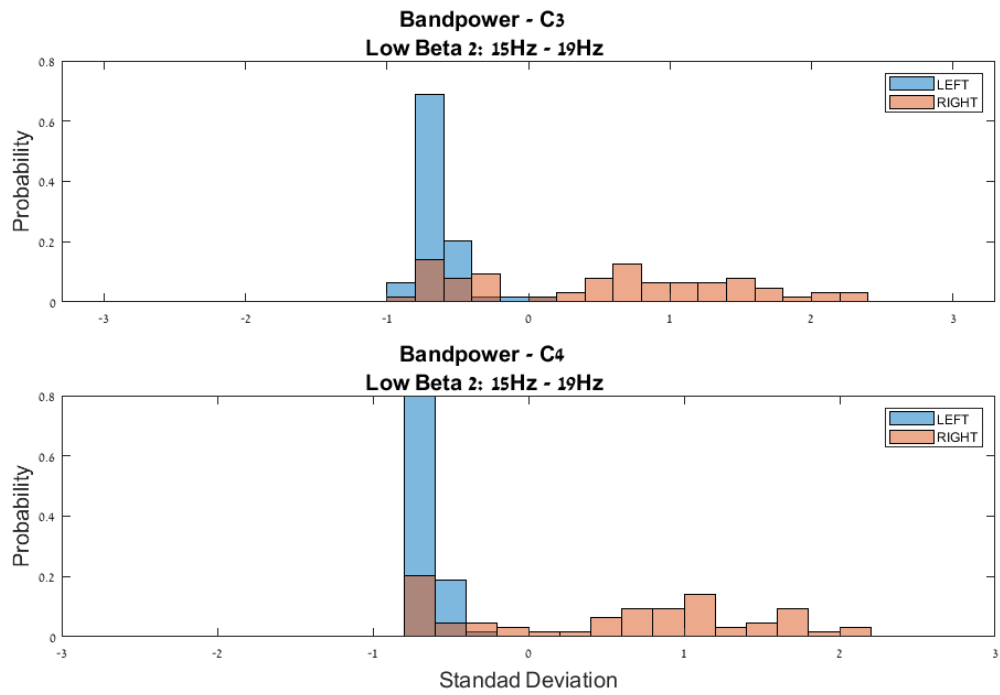
הסתברות הסיגנל כתלות בסטיית התקן, כשהנבדק דמיון "ימין" (כתום) ו"שמאל" (כחול), עבור תדר Low Beta, 1, עבור הקלטה מאלקטרודה C3 ו-C4:



הסתברות הסיגנל כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כתום) ו"שמאל" (כחול), עבור תדר Low Beta 1 ביחס לתדרים הנוספים, עבור הקלטה מאלקטרודה C3 ו-C4:



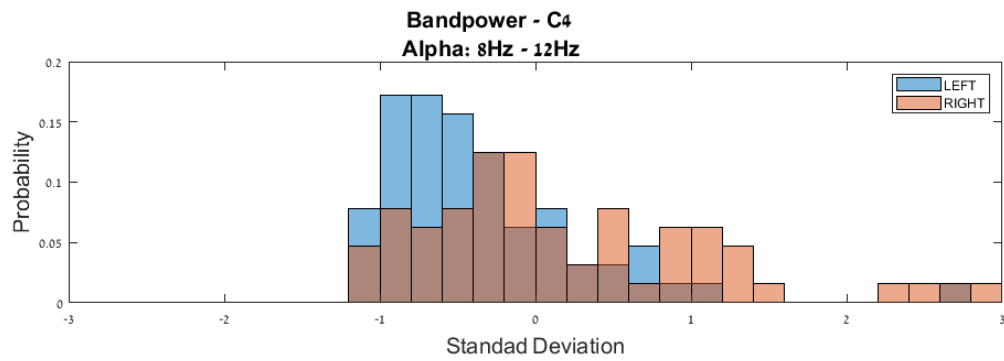



הסתברות הסיגנל כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כתום) ו"שמאל" (כחול), עבור תדר Low Beta 2, עבור הקלטה מאלקטרודה C3 ו-C4:

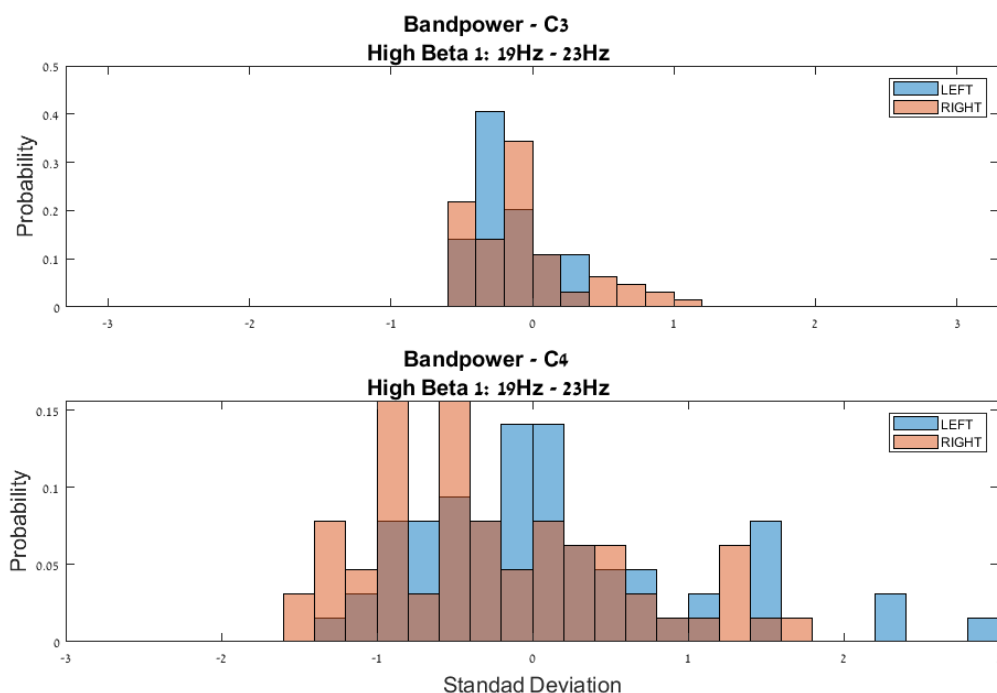


הסתברות הסיגנל כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כתום) ו"שמאל" (כחול), עבור תדר Low Beta


2 ביחס לתדרים הנוספים, עבור הקלטה מאלקטרודה C3 ו-C4:




הסתברות הסיגנל כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כתום) ו"שמאל" (כחול), עבור תדר High Beta 1, עובר הקלטה מאלקטרודה C3 ו-C4:



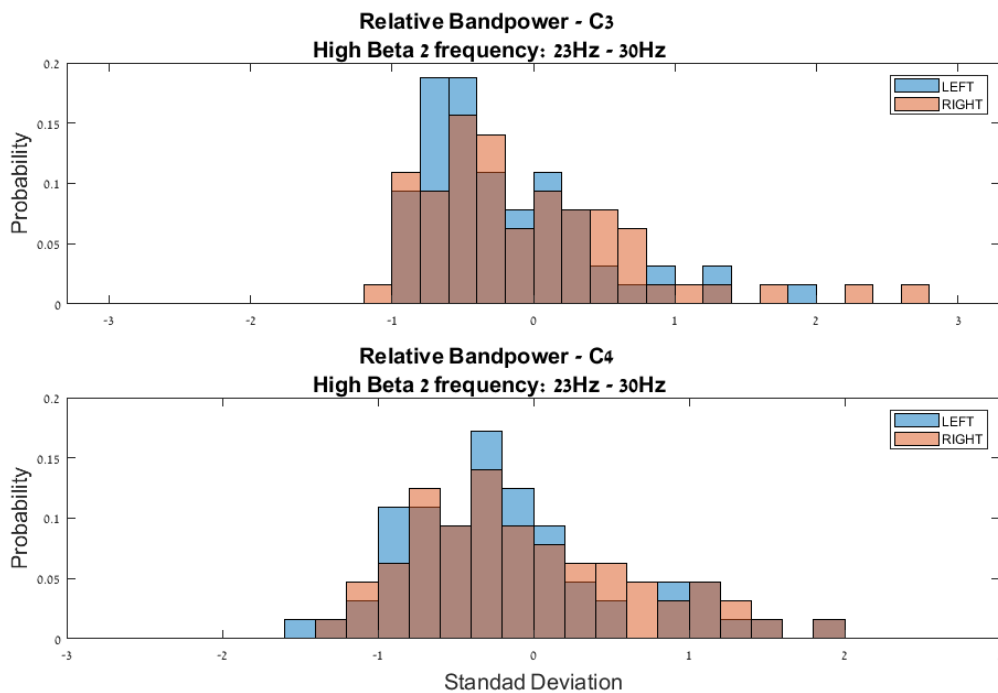
הסתברות הסיגנל כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כתום) ו"שמאל" (כחול), עבור תדר High Beta 1 ביחס לתדרים הנוספים, עובר הקלטה מאלקטרודה C3 ו-C4:



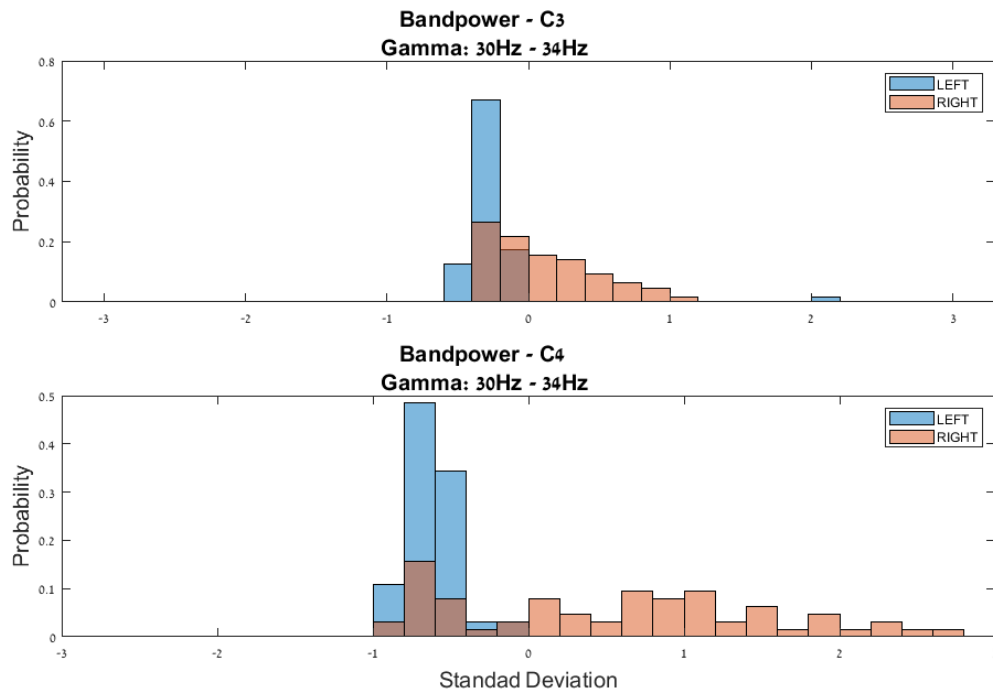
הסתברות הסיגנל כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כתום) ו"שמאל" (כחול), עבור תדר High Beta 2, עובר הקלטה מאלקטרודה C3 ו-C4:



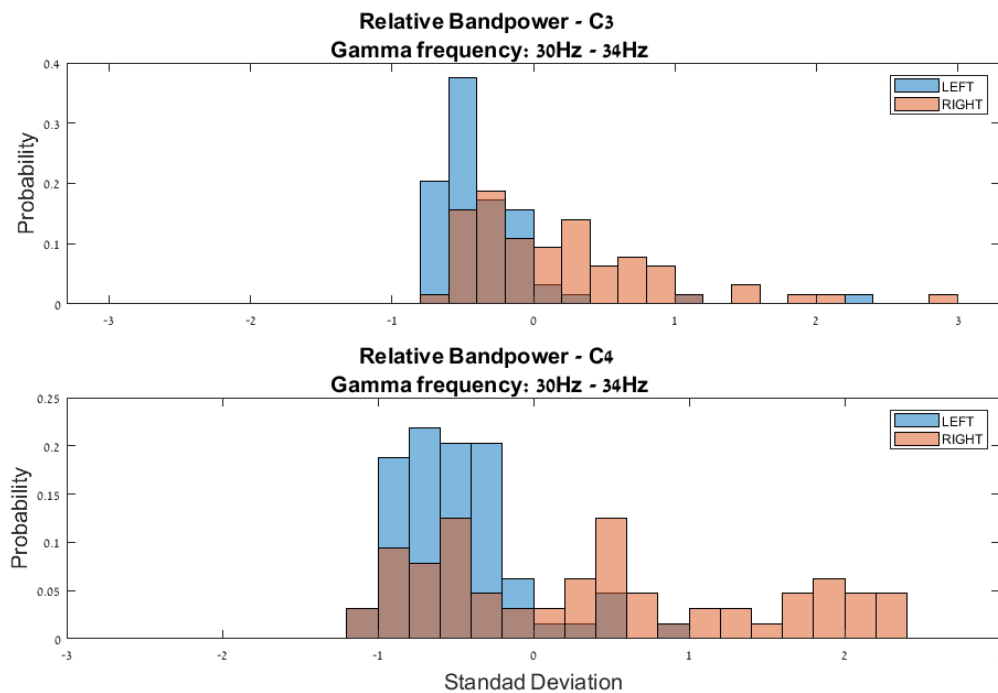
הסתברות הסיגנל כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כתום) ו"שמאל" (כחול), עבור תדר High Beta 2 ביחס לתדרים הנוספים, עבור הקלטה מאלקטרודה C3 ו-C4:



הסתברות הסיגנל כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כתום) ו"שמאל" (כחול), עבור תדר Gamma, עבור הקלטה מאלקטרודה C3 ו-C4:

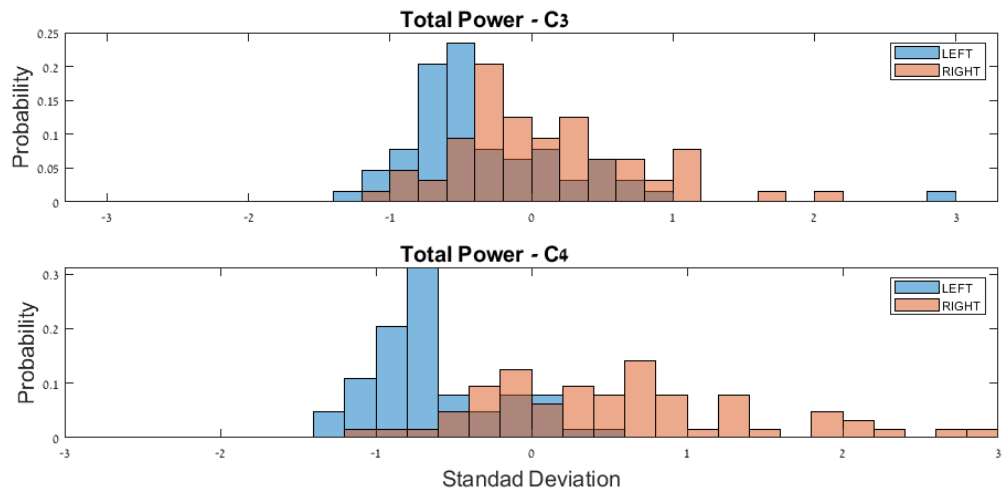


הסתברות הסיגנל כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כתום) ו"שמאל" (כחול), עבור תדר Gamma ביחס לתדרים הנוספים, עבור הקלטה מאלקטרודה C3 ו-C4:




:Total Power

הסתברות כלל העצמה כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כתום) ו"שמאל" (כחול), עבור הקלטה מאלקטרודה C3 ו-C4.



:Root Total Power

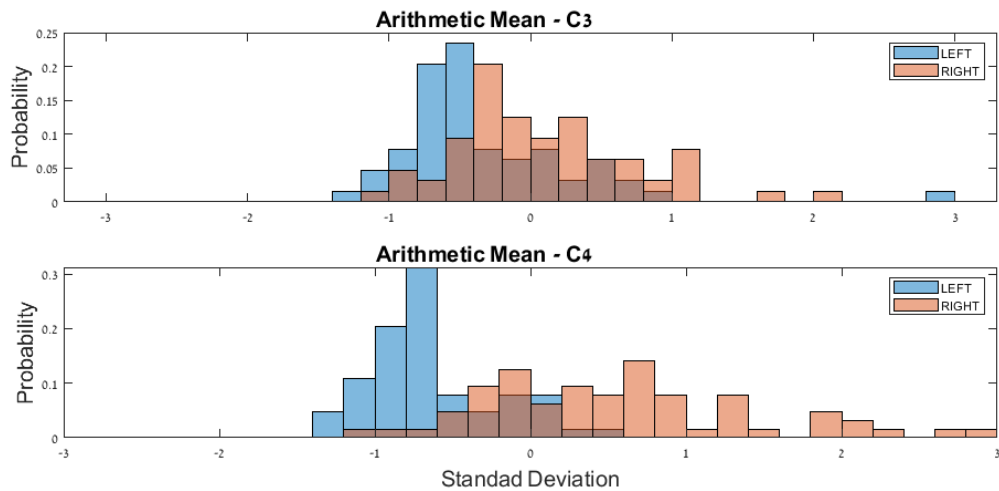
הסתברות שורש כלל העצמה כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כתום) ו"שמאל" (כחול), עבור הקלטה מאלקטרודה C3 ו-C4.



:Arithmetic mean




הסתברות הממוצע האריתמטי כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כתום) ו"שמאל" (כחול), עבור הקלטה מאלקטרונית C3 ו-C4.



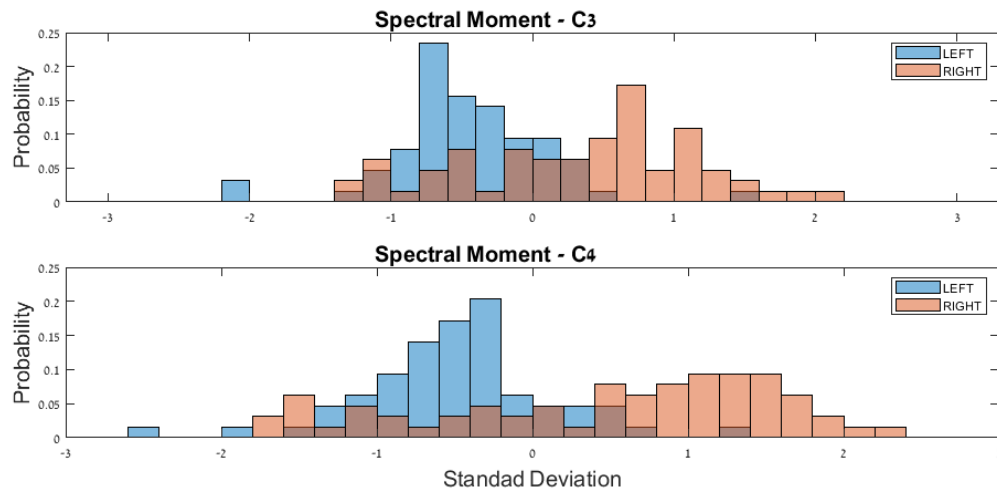
### :Mean Curb Length

הסתברות ממוצע אורכי השיפועים כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כתום) ו"שמאל" (כחול), עבור הקלטה מאלקטרונית C3 ו-C4.



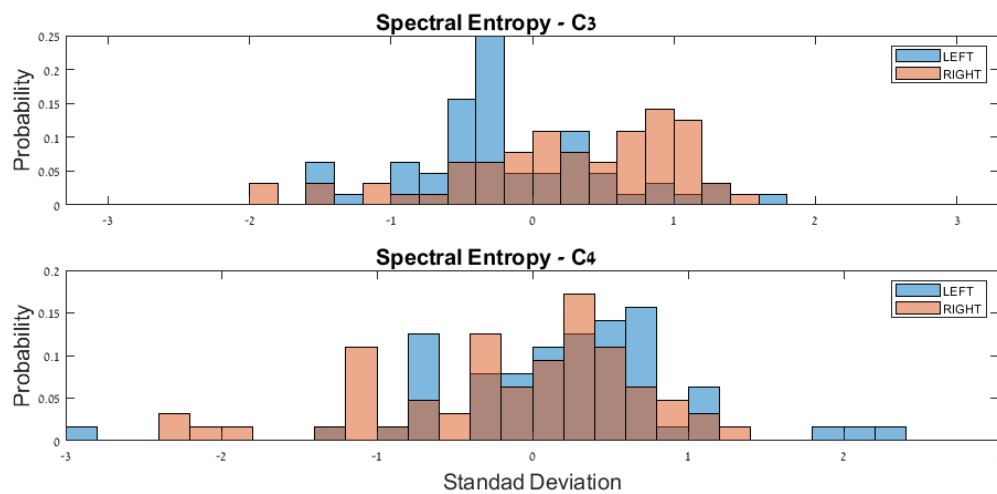
### :Spectral Moment

הסתברות ספקטרל רגעי כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כתום) ו"שמאל" (כחול), עבור הקלטה מאלקטרונית C3 ו-C4.



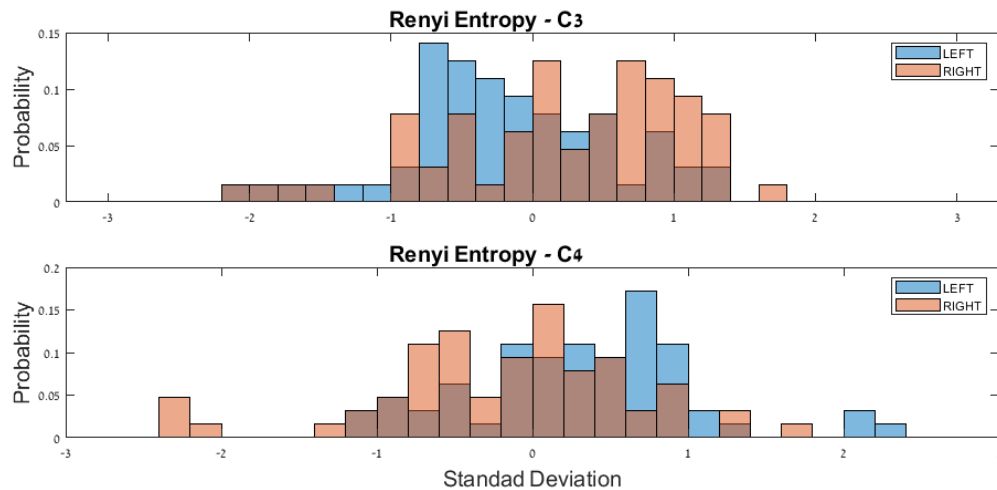
### :Spectral Entropy

הסתברות אנטרופיה ספקטרלית כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כתום) ו"שמאל" (כחול), עבור הקלטה מאלקטרודה C3 ו-C4.



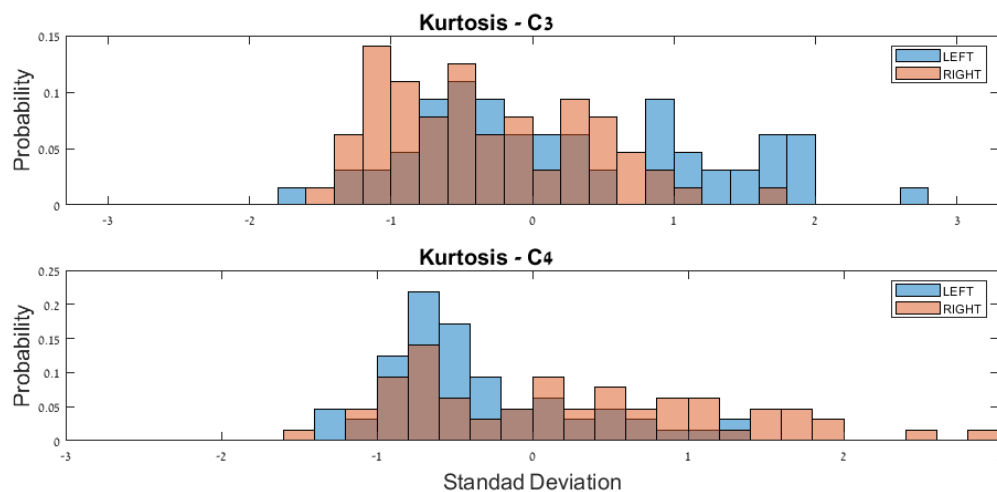
### :Renyi Entropy

הסתברות אנטרופיית רני כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כחול) ו"שמאל" (כתום), עבור הקלטה מאלקטרודה C3 ו-C4.



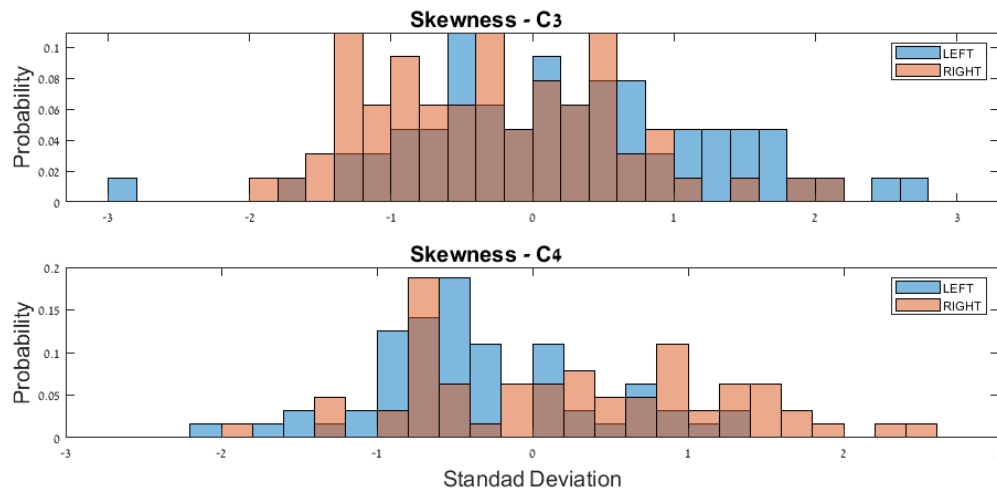
### :Kurtosis

הסתברות גבנוניות כולות בסטיית התקן, כשהנבדק דמיין "ימין" (כתום) ו"שמאל" (כחול), עבור הקלטה מאלקטרונית C3 ו-C4.




### :Skewness

הסתברות צידוד כולות בסטיית התקן, כשהנבדק דמיין "ימין" (כתום) ו"שמאל" (כחול), עבור הקלטה מאלקטרונית C3 ו-C4.



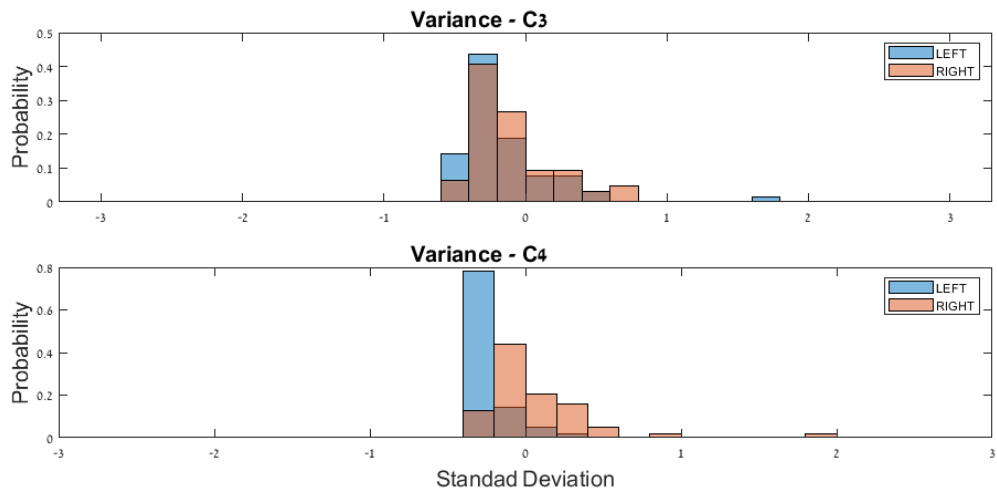
### :Standard Deviation

הסתברות סטיית תקן כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כחול) ו"שמאל" (כתום), עבור הקלטה מאלקטרודה C3 ו-C4.




### :Variance

הסתברות שונות כתלות בסטיית התקן, כשהנבדק דמיין "ימין" (כחול) ו"שמאל" (כתום), עבור הקלטה מאלקטרודה C3 ו-C4.





### Confusion matrix

טבלה המייצגת את מספר הפעמים בהם התרחשו קומבינציות- המורכבות מתחזית תיוג האלגוריתם (ציר ה-X) וכוונת הנבדק (ציר ה-Y):




### Feature selection optimization

גרף תוצאות ההרצה 951 פעמים. אחוז דיוק הניבוי כתלות במס' המאפיינים.



### PCA:

נתוני ה-PCR התלת והדו מימדיים (ימין ושמאל בהתאמה). ציר ה-X: קואורדינטת ה-PCR הראשונה, Y-  
השנייה, Z- השלישית. עבור דמיון הנבדק "ימין" (אדום) ו"שמאל" (כחול)




### דינו:

בעבודה זו בנינו מודל לניבוי איזה יד הנבדק מדמיין שהוא מזיז ע"י ניתוח נתוני EEG מאלקטרודות C3 וC4. לבניית המנבא ניתחנו את נתוני ה-EEG ובנינו מטריצת פיצ'רים אופטימלית ע"י בחירת הפיצ'רים המשמעותיים ביותר לביצוע הניבוי.

על מנת לחלץ נתונים אינפורמטיביים מנתוני ה-EEG השתמשנו בטרנספורמצית וולץ' להערכת צפיפות ספקטרלית. מתוצאות התמרה זו בשתי האלקטרודות יכולנו לראות כי ישנם הבדלים בין האלקטרודות בעיקר בין 15 ל19 הרץ. ההפרש בין קו 1 לקו 2 ( $1.9714=2.0071-0.6019$ ) באיור ה-power spectrum מלמד כי C4 הינה האלקטרודה הסיגניפיקנטית יותר בלמידת ההבדל בין הצדדים.

איור *power spectrum*:



בהתאם לתדירים בהם השינוי גדול ביותר בחרנו את התדירים powerbands. תדר low beta הינו בתחום תדירים זה וכך ניתן לראות כי בטווח low beta 2 שהינו בין 15 ל 19 הרץ נמצא ההבדל הגדול ביותר בין הצדדים. תדירים אלו קשורים לאיזורים בקורטקס האחראיים על בקרה מוטורית (Jurkiewicz, M. T. et al 2006).

על מנת להגיע לאחוז הדיוק הגבוה ביותר בהבדל בין הצדדים בחרנו להשתמש במגוון רחב של פיצ'רים שונים למציאת מגוון הבדלים בין הצדדים. בחרנו את הפיצ'רים על מנת שיענו על מספר אספקטים; ערכי העצמה והתדירות, קצב השינוי של עצמה כתלות בתדירות, מידת האינפורמציה של העצמה כתלות בתדירות ואספקטים אלו בהתחשבות בהשפעה היחסית של מידת העצמה כתלות בתדירות. (Inuso, G., La Foresta et al 2007), (Riaz, F., Hassan et al 2015), (Zhang, C., et al 2013)

מתוך פיצ'רים אלו בנינו אלגוריתם לבחירת הפיצ'רים האופטימליים ורק בהם השתמשנו. בעזרת שיטה זו הצלחנו להגיע לאחוזים של כ-88.8% (ס"ת 1.43%) של דיוק בין בלימוד האלגוריתם להבדיל בין הצדדים. המדידה התבצעה ע"י הרצת המנבא 951 פעמים ומציאת ממוצע הוולידציה.

בגרפי אופטימיזצית בחירת הפיצ'רים ניתן לראות כי מספר הפיצ'רים המינימלי לקיום סיווג הינו 5, וכי ב-80.55% מהמקרים נמצא כי מספר הפיצ'רים המקסימלי 11 הינו האופטימלי. מכך אנו מסיקים כי לרוב יש חשיבות לכל הפיצ'רים שבחרנו. בנוסף קו המגמה החיובי (0.71 אחוז דיוק לפיצ'ר) מלמד כי מספר רב יותר של פיצ'רים נוטה להעלות את אחוז הדיוק.

לסיכום, אחוז הדיוק של 88.8% (ס"ת 1.43%) מראה שניתן לנבא בצורה טובה את צד דמיון התנועה מנתוני שתי אלקטרודות C3 ו C4. אך תוצאות אלו אינן מנבאות בוודאות, ייתכן כי יש למצוא מאפיינים נוספים ודאטא נוסף



לעבד על מנת לשפר את יכולות הניבוי. בנוסף ייתכן כי ישנם אזורים נוספים האחראיים על שליטה מוטורית ולכן נדרשת גם הוספת אלקטרודות לאיזורים נוספים על מנת לשפר את יכולת המנבא. (Wang, Y., & Makeig, S. 2009)

מקורות:

- Aggarwal, S., & Chugh, N. (2019). Signal processing techniques for motor imagery brain computer interface: A review. *Array*, 1, 100003.
- Akbar, Y., Khotimah, S. N., & Haryanto, F. (2016, March). Spectral and brain mapping analysis of EEG based on Pwelch in schizophrenic patients. In *Journal of Physics: Conference Series* (Vol. 694, No. 1, p. 012070). IOP Publishing.
- Badillo, S., Banfai, B., Birzele, F., Davydov, I. I., Hutchinson, L., Kam-Thong, T., ... & Zhang, J. D. (2020). An introduction to machine learning. *Clinical Pharmacology & Therapeutics*, 107(4), 871-885.
- Decety, J. (1996). The neurophysiological basis of motor imagery. *Behavioural brain research*, 77(1-2), 45-52.
- Doucet, G. E., Sharan, A., Pustina, D., Skidmore, C., Sperling, M. R., & Tracy, J. I. (2015). Early and late age of seizure onset have a differential impact on brain resting-state organization in temporal lobe epilepsy. *Brain topography*, 28(1), 113-126.
- Gao, X., Xu, D., Cheng, M., & Gao, S. (2003). A BCI-based environmental controller for the motion-disabled. *IEEE Transactions on neural systems and rehabilitation engineering*, 11(2), 137-140.
- Höller, Y., Bergmann, J., Thomschewski, A., Kronbichler, M., Höller, P., Crone, J. S., ... & Trinka, E. (2013). Comparison of EEG-features and classification methods for motor imagery in patients with disorders of consciousness. *PloS one*, 8(11), e80479.
- Inuso, G., La Foresta, F., Mammone, N., & Morabito, F. C. (2007, July). Brain activity investigation by EEG processing: wavelet analysis, kurtosis and Renyi's entropy for artifact detection. In *2007 International Conference on Information Acquisition* (pp. 195-200). IEEE.
- Jabbar, H., & Khan, R. Z. (2015). Methods to avoid over-fitting and under-fitting in supervised machine learning (comparative study). *Computer Science, Communication and Instrumentation Devices*, 163-172.

- Jurkiewicz, M. T., Gaetz, W. C., Bostan, A. C., & Cheyne, D. (2006). Post-movement beta rebound is generated in motor cortex: evidence from neuromagnetic recordings. *Neuroimage*, 32(3), 1281-1289.
- Lee, J., Park, J., Yang, S., Kim, H., Choi, Y. S., Kim, H. J., ... & Lee, B. U. (2017). Early seizure detection by applying frequency-based algorithm derived from the principal component analysis. *Frontiers in neuroinformatics*, 11, 52.
- Liang, S. F., Chen, Y. C., Wang, Y. L., Chen, P. T., Yang, C. H., & Chiueh, H. (2013). A hierarchical approach for online temporal lobe seizure detection in long-term intracranial EEG recordings. *Journal of neural engineering*, 10(4), 045004.
- Penfield, W., & Jasper, H. (1954). Epilepsy and the functional anatomy of the human brain.
- Riaz, F., Hassan, A., Rehman, S., Niazi, I. K., & Dremstrup, K. (2015). EMD-based temporal and spectral features for the classification of EEG signals using supervised learning. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 24(1), 28-35.
- Smith, S. J. (2005). EEG in the diagnosis, classification, and management of patients with epilepsy. *Journal of Neurology, Neurosurgery & Psychiatry*, 76(suppl 2), ii2-ii7.
- Vega-Escobar, L., Castro-Ospina, A. E., & Duque-Muñoz, L. (2015, September). Feature extraction schemes for BCI systems. In *2015 20th symposium on signal processing, images and computer vision (STSIVA) (pp. 1-6)*. IEEE.
- Wang, Y., & Makeig, S. (2009, July). Predicting intended movement direction using EEG from human posterior parietal cortex. In *International Conference on Foundations of Augmented Cognition* (pp. 437-446). Springer, Berlin, Heidelberg.
- Yang, J., Zhang, D., Frangi, A. F., & Yang, J. Y. (2004). Two-dimensional PCA: a new approach to appearance-based face representation and recognition. *IEEE transactions on pattern analysis and machine intelligence*, 26(1), 131-137.
- Zhang, C., Wang, H., & Wu, M. H. (2013). EEG-based expert system using complexity measures and probability density function control in alpha sub-band. *Integrated computer-aided engineering*, 20(4), 391-405.

נספחים:

- תוצאות הרצת המנבא 951 פעמים:

Number of features	Validation Accuracy [%]
11	87.53443526
11	89.94490358
11	89.1184573
11	91.39118457
11	90.0137741
11	89.18732782
11	86.08815427
11	90.0137741
11	87.46556474
11	89.73829201
11	86.15702479
11	88.84297521
10	86.50137741
10	86.57024793
11	90.35812672
11	88.2231405
10	86.63911846
11	88.29201102
10	89.25619835
11	89.94490358

11	88.42975207
11	89.04958678
11	89.87603306
11	90.70247934
11	88.29201102
11	89.60055096
10	87.67217631
11	88.2231405
11	87.0523416
11	89.18732782
6	85.19283747
11	88.98071625
11	88.29201102
11	88.36088154
9	85.05509642
11	90.49586777
11	88.29201102
11	89.1184573
11	87.53443526
11	89.1184573
11	89.04958678

11	89.87603306
11	91.52892562
10	88.84297521
11	87.53443526
10	86.70798898
11	87.60330579
11	89.80716253
11	89.60055096
11	89.94490358
10	88.36088154
11	89.73829201
11	88.36088154
11	88.08539945
11	89.87603306
11	86.7768595
11	89.80716253
11	88.15426997
10	88.29201102
11	89.94490358
11	88.98071625
11	89.18732782

11	90.70247934
11	88.36088154
11	88.98071625
11	90.77134986
11	91.39118457
11	89.80716253
11	89.87603306
11	89.04958678
11	87.74104683
11	90.84022039
11	89.94490358
11	87.32782369
11	88.98071625
6	85.95041322
11	88.2231405
11	90.63360882
11	89.04958678
10	87.53443526
11	88.91184573
10	87.53443526
11	88.36088154

11	89.80716253
11	89.94490358
11	89.04958678
11	88.91184573
7	86.01928375
10	87.60330579
11	89.87603306
11	89.87603306
11	90.77134986
11	87.53443526
7	86.63911846
11	88.36088154
11	89.73829201
11	90.49586777
11	87.46556474
10	89.1184573
11	89.66942149
11	88.29201102
11	90.70247934
11	89.18732782
10	88.08539945

11	90.0137741
11	88.36088154
10	86.84573003
11	90.0137741
10	87.39669421
10	85.81267218
11	89.87603306
11	90.84022039
10	87.46556474
11	88.2231405
10	86.7768595
11	88.15426997
11	86.7768595
9	84.36639118
11	89.04958678
11	88.15426997
11	88.36088154
11	89.80716253
11	89.1184573
11	88.36088154
10	86.36363636



11	88.98071625
11	88.36088154
11	91.184573
11	89.73829201
11	89.80716253
11	89.66942149
11	86.70798898
10	86.7768595
11	89.80716253
11	90.49586777
6	86.01928375
11	91.32231405
11	88.2231405
11	89.25619835
10	87.32782369
11	92.21763085
11	89.32506887
10	85.05509642
10	86.7768595
11	89.04958678
11	88.98071625

11	89.80716253
11	91.32231405
11	87.53443526
11	90.56473829
10	87.32782369
11	90.84022039
11	88.15426997
10	88.91184573
11	88.29201102
11	88.29201102
11	88.29201102
11	89.18732782
11	88.2231405
10	87.39669421
11	88.84297521
11	91.39118457
11	89.94490358
11	90.49586777
11	89.04958678
11	89.66942149
11	87.39669421

11	88.63636364
11	88.01652893
11	88.91184573
6	86.7768595
11	88.98071625
11	87.53443526
11	90.70247934
11	88.49862259
11	89.87603306
11	87.67217631
11	88.29201102
11	90.70247934
10	87.46556474
11	87.60330579
11	89.18732782
11	90.49586777
11	90.70247934
11	89.25619835
11	89.94490358
11	89.04958678
11	86.50137741

10	88.2231405
11	89.94490358
11	89.80716253
11	90.70247934
11	87.25895317
11	89.73829201
6	86.57024793
11	88.91184573
11	88.36088154
11	89.73829201
11	89.87603306
11	90.63360882
11	87.46556474
11	89.73829201
10	84.36639118
11	90.63360882
11	88.98071625
11	87.67217631
10	89.1184573
11	88.84297521
11	88.08539945

11	88.49862259
11	88.36088154
11	91.32231405
11	89.80716253
11	88.15426997
11	90.63360882
11	88.08539945
11	88.15426997
11	89.80716253
10	86.84573003
11	88.98071625
11	91.4600551
10	87.53443526
11	88.56749311
11	89.18732782
11	87.60330579
11	89.32506887
11	89.94490358
11	90.56473829
11	88.2231405
11	87.67217631

11	88.42975207
11	88.98071625
10	88.70523416
10	87.39669421
11	87.19008264
11	88.98071625
10	89.1184573
11	87.0523416
11	90.63360882
11	90.56473829
5	86.57024793
11	90.70247934
11	88.36088154
10	88.15426997
11	87.53443526
11	89.04958678
11	88.63636364
11	89.87603306
11	89.1184573
11	87.67217631
11	90.70247934

6	86.57024793
11	89.80716253
11	89.80716253
11	88.91184573
11	88.36088154
11	88.2231405
11	89.80716253
11	90.84022039
11	89.04958678
11	90.49586777
11	88.98071625
11	90.49586777
11	91.32231405
11	89.87603306
11	89.80716253
11	86.7768595
11	88.2231405
11	89.80716253
11	88.98071625
11	89.04958678
10	88.42975207

10	88.98071625
10	85.81267218
11	89.04958678
11	90.70247934
11	86.7768595
11	86.01928375
10	87.67217631
11	86.08815427
10	88.2231405
11	89.04958678
11	88.15426997
10	87.67217631
11	90.49586777
11	88.36088154
11	90.0137741
11	88.29201102
11	91.32231405
11	90.63360882
11	88.36088154
11	89.1184573
11	88.98071625



11	88.42975207
11	89.73829201
11	90.35812672
11	90.63360882
10	89.1184573
11	88.36088154
11	91.4600551
11	88.15426997
10	89.18732782
11	90.70247934
10	87.32782369
10	85.74380165
11	91.4600551
11	87.39669421
11	90.0137741
11	89.1184573
11	90.63360882
11	90.84022039
11	91.32231405
11	89.87603306
11	90.77134986

11	91.11570248
11	89.73829201
11	89.73829201
11	88.2231405
11	89.87603306
11	89.80716253
11	89.94490358
11	91.39118457
10	86.63911846
11	88.98071625
11	89.18732782
11	87.46556474
10	86.84573003
10	88.36088154
11	90.63360882
10	87.32782369
11	90.08264463
11	89.04958678
11	86.08815427
11	89.80716253
11	89.87603306

11	89.18732782
10	88.36088154
11	89.1184573
11	88.42975207
10	89.04958678
11	88.2231405
11	86.63911846
11	87.39669421
10	89.87603306
11	88.36088154
11	88.29201102
11	88.36088154
11	85.81267218
11	89.80716253
11	90.77134986
11	89.1184573
11	89.80716253
11	89.60055096
11	89.1184573
11	89.1184573
11	91.39118457

11	90.77134986
11	88.49862259
10	88.2231405
10	88.29201102
11	88.29201102
11	89.1184573
10	86.91460055
11	89.04958678
11	91.52892562
11	87.39669421
11	92.14876033
11	89.18732782
11	88.2231405
11	88.29201102
11	91.25344353
7	86.01928375
11	89.18732782
10	88.98071625
11	91.4600551
11	90.0137741
11	86.01928375

11	90.77134986
11	87.53443526
11	88.2231405
10	87.32782369
10	86.7768595
10	86.43250689
11	89.80716253
11	89.73829201
11	88.98071625
11	88.15426997
11	89.04958678
11	89.18732782
11	88.98071625
11	89.94490358
11	89.04958678
11	89.73829201
10	87.39669421
11	86.63911846
11	91.32231405
11	88.29201102
11	90.63360882

11	88.42975207
10	87.25895317
6	85.12396694
11	88.2231405
11	87.46556474
11	89.73829201
11	87.32782369
10	86.43250689
11	88.29201102
11	90.77134986
11	88.91184573
10	87.80991736
7	85.26170799
11	89.18732782
11	88.91184573
6	85.95041322
7	87.46556474
11	90.0137741
11	89.04958678
11	90.49586777
11	88.29201102

11	90.56473829
11	90.56473829
11	87.60330579
11	87.9476584
11	89.87603306
11	89.1184573
11	87.46556474
11	87.46556474
11	88.36088154
11	86.63911846
11	88.98071625
11	90.70247934
11	89.73829201
11	88.36088154
10	87.60330579
10	86.70798898
5	86.7768595
10	86.7768595
5	86.63911846
11	89.60055096
11	90.63360882

11	90.08264463
5	86.01928375
11	88.29201102
11	89.1184573
11	92.01101928
9	87.39669421
5	86.63911846
11	86.98347107
11	89.04958678
11	89.1184573
11	89.80716253
11	88.98071625
11	88.91184573
11	90.70247934
11	88.98071625
11	89.1184573
11	88.49862259
11	90.77134986
10	88.42975207
10	88.91184573
11	89.04958678



11	90.63360882
10	86.84573003
10	87.53443526
11	90.77134986
11	88.91184573
11	90.63360882
11	90.0137741
9	85.26170799
11	90.63360882
10	89.94490358
11	88.42975207
10	87.60330579
11	88.42975207
11	89.66942149
10	87.32782369
11	87.32782369
11	89.18732782
11	89.80716253
11	86.57024793
11	88.98071625
6	86.70798898

11	89.25619835
11	88.15426997
11	87.32782369
11	88.29201102
11	89.73829201
11	90.49586777
11	91.32231405
11	91.25344353
11	90.63360882
11	88.29201102
11	89.87603306
11	90.49586777
11	88.29201102
11	88.98071625
11	90.70247934
11	90.42699725
11	87.74104683
11	88.49862259
11	86.57024793
11	89.1184573
11	88.91184573

11	88.29201102
11	89.87603306
11	89.73829201
11	86.01928375
11	89.80716253
11	90.49586777
11	88.36088154
11	88.36088154
10	88.29201102
11	88.98071625
11	88.2231405
11	89.66942149
11	90.35812672
11	87.39669421
11	88.84297521
11	87.53443526
10	87.53443526
11	89.80716253
11	89.1184573
11	89.87603306
11	89.1184573

11	89.1184573
11	92.97520661
11	90.49586777
11	89.66942149
11	88.29201102
11	89.87603306
11	90.70247934
11	87.60330579
10	88.08539945
11	88.2231405
11	91.4600551
11	89.94490358
11	87.39669421
11	88.91184573
10	86.63911846
11	88.36088154
11	89.04958678
11	89.80716253
11	92.28650138
11	89.1184573
11	90.0137741

11	89.87603306
10	89.73829201
11	89.1184573
11	88.08539945
10	88.29201102
11	89.1184573
11	88.91184573
10	85.8815427
11	88.84297521
11	89.04958678
11	89.04958678
11	90.70247934
11	91.39118457
11	89.04958678
10	88.15426997
11	89.1184573
11	90.56473829
11	89.80716253
10	89.80716253
11	88.36088154
11	90.56473829

11	91.32231405
11	87.53443526
11	89.94490358
11	88.36088154
11	89.1184573
10	88.36088154
11	88.42975207
11	89.87603306
7	87.53443526
11	90.63360882
11	89.18732782
11	89.80716253
10	88.42975207
11	89.18732782
11	88.91184573
11	88.36088154
11	90.63360882
11	91.25344353
11	88.15426997
11	90.70247934
11	86.84573003

11	89.66942149
11	89.94490358
11	89.80716253
11	87.60330579
11	88.98071625
11	89.04958678
11	88.36088154
10	86.50137741
11	87.46556474
11	91.59779614
11	90.56473829
11	88.91184573
11	89.94490358
11	89.87603306
11	89.04958678
10	89.18732782
11	88.01652893
11	90.56473829
11	90.08264463
11	89.87603306
11	91.39118457

11	86.63911846
11	90.70247934
11	89.80716253
11	87.32782369
10	86.70798898
11	90.56473829
11	85.74380165
11	87.67217631
11	85.26170799
10	88.29201102
6	85.8815427
9	85.12396694
11	90.56473829
11	89.04958678
10	89.04958678
11	90.42699725
11	89.87603306
11	89.04958678
11	89.87603306
10	88.29201102
11	90.63360882



11	90.56473829
11	88.36088154
11	88.56749311
10	88.42975207
10	89.18732782
11	90.70247934
10	86.91460055
11	89.73829201
11	89.66942149
11	90.56473829
11	89.1184573
11	88.91184573
7	86.08815427
11	87.39669421
11	87.60330579
11	89.94490358
11	89.80716253
11	89.1184573
10	85.8815427
10	87.39669421
11	90.0137741

11	91.39118457
11	90.56473829
11	89.87603306
11	86.63911846
10	87.74104683
11	87.46556474
11	89.04958678
11	88.2231405
7	86.57024793
11	87.80991736
10	88.29201102
11	90.49586777
11	90.77134986
11	89.80716253
11	89.87603306
9	86.01928375
10	87.53443526
11	90.56473829
6	87.46556474
11	90.77134986
11	89.66942149

11	90.0137741
11	89.66942149
11	87.67217631
11	88.29201102
6	85.81267218
10	87.53443526
11	91.52892562
11	89.1184573
11	90.49586777
11	87.25895317
11	86.7768595
11	88.15426997
11	89.80716253
11	89.04958678
11	89.1184573
11	87.46556474
11	89.87603306
11	88.29201102
11	89.18732782
10	88.36088154
11	88.42975207

11	90.56473829
10	86.7768595
11	87.60330579
11	89.87603306
10	88.49862259
11	89.18732782
11	88.01652893
11	90.56473829
6	88.36088154
11	88.29201102
11	89.80716253
11	89.94490358
11	88.29201102
11	89.87603306
10	88.98071625
11	89.60055096
10	86.98347107
11	89.66942149
11	88.98071625
11	88.36088154
11	90.63360882

10	87.46556474
11	88.49862259
11	90.63360882
9	87.25895317
10	88.15426997
11	89.73829201
11	91.25344353
10	86.84573003
11	89.25619835
11	89.80716253
11	87.67217631
11	89.94490358
11	90.70247934
11	89.87603306
11	90.0137741
10	88.42975207
11	90.63360882
11	90.0137741
11	88.91184573
11	89.80716253
10	87.53443526

11	90.0137741
11	88.15426997
11	90.77134986
11	88.2231405
10	86.63911846
11	89.66942149
11	89.87603306
11	90.56473829
11	88.49862259
11	89.66942149
11	88.98071625
10	89.32506887
11	89.80716253
11	91.39118457
11	89.87603306
11	89.04958678
11	88.2231405
11	90.70247934
11	89.87603306
11	88.36088154
11	88.36088154

10	86.08815427
11	88.91184573
11	89.87603306
7	85.67493113
11	87.53443526
11	89.80716253
11	88.91184573
11	89.80716253
10	88.29201102
11	89.73829201
11	89.94490358
10	85.95041322
11	89.04958678
11	87.60330579
11	90.63360882
11	88.98071625
11	89.87603306
11	88.2231405
11	90.56473829
11	89.87603306
11	87.25895317

11	88.08539945
11	87.39669421
11	89.1184573
11	91.32231405
11	88.36088154
11	89.04958678
11	90.63360882
10	88.08539945
11	87.32782369
11	90.77134986
10	85.74380165
11	92.07988981
11	89.87603306
11	89.73829201
11	88.98071625
11	89.73829201
7	86.63911846
11	90.0137741
10	88.36088154
11	89.04958678
11	89.25619835



11	90.42699725
10	87.39669421
11	88.98071625
11	89.04958678
11	89.18732782
10	87.46556474
11	90.56473829
7	86.7768595
10	89.04958678
11	91.4600551
10	86.63911846
11	89.04958678
11	90.63360882
11	89.94490358
11	89.04958678
11	88.29201102
11	89.1184573
10	87.46556474
11	88.15426997
10	88.15426997
11	89.18732782

11	88.91184573
11	88.29201102
11	87.46556474
11	87.19008264
11	89.04958678
11	89.25619835
10	88.29201102
11	88.36088154
11	90.49586777
11	86.50137741
11	89.04958678
10	89.18732782
11	89.66942149
11	89.94490358
11	89.94490358
10	87.32782369
11	88.29201102
11	87.32782369
10	87.39669421
11	87.53443526
11	86.70798898

11	87.60330579
11	89.18732782
11	87.32782369
11	89.80716253
11	88.15426997
11	89.87603306
11	89.60055096
9	85.95041322
11	89.1184573
11	90.63360882
11	91.4600551
5	85.8815427
11	88.98071625
11	89.04958678
11	91.4600551
11	87.39669421
11	89.80716253
11	89.1184573
10	89.04958678
11	89.94490358
11	91.52892562

10	89.04958678
11	91.39118457
11	88.01652893
7	85.19283747
11	89.1184573
11	86.7768595
11	90.0137741
6	88.56749311
10	89.18732782
11	89.87603306
11	88.91184573
11	86.70798898
11	87.53443526
11	86.70798898
10	88.36088154
10	87.60330579
10	88.91184573
11	89.73829201
11	88.36088154
11	90.0137741
10	87.53443526

11	89.80716253
11	91.52892562
11	89.80716253
11	88.91184573
11	88.15426997
11	89.73829201
11	88.29201102
11	91.25344353
11	90.56473829
11	88.29201102
11	88.98071625
10	86.57024793
11	89.25619835
11	91.32231405
6	85.05509642
11	89.1184573
11	89.39393939
11	89.1184573
11	88.15426997
11	90.70247934
11	89.18732782

11	87.67217631
11	89.80716253
11	87.46556474
6	86.63911846
11	88.15426997
11	89.18732782
11	88.2231405
11	89.80716253
11	89.73829201
11	90.56473829
11	87.39669421
11	88.08539945
11	89.80716253
11	89.80716253
11	90.77134986
11	89.04958678
11	89.1184573
11	88.77410468
11	89.04958678
11	89.66942149
11	88.42975207

11	88.98071625
11	87.25895317
10	87.53443526
11	90.84022039
11	89.04958678
10	87.39669421
11	92.14876033
11	88.15426997
11	88.29201102
10	87.32782369
11	92.07988981
10	88.29201102
11	86.57024793
11	89.80716253
11	90.0137741
11	88.15426997
11	90.56473829
9	87.46556474
11	89.94490358
11	91.52892562
11	89.80716253

11	88.91184573
11	88.15426997
11	89.66942149
10	84.9862259
11	89.04958678
11	88.42975207
11	90.0137741